

Klasifikasi Sel Sumsum Tulang Belakang Menggunakan Deep Learning Berbasis CNN ReXNet-150 dan GUI Berbasis Web

Kizza Naufal Syawalsyah¹, Haydar Alsagaff², Adonnai Phylosophia Cinta Ngau³

^{1,2,3} Program Studi Teknik Biomedik, Departemen Teknik Elektro, Fakultas Teknik, Universitas Indonesia

kizza.naufal@ui.ac.id, haydar.alsagaff@ui.ac.id, adonnai.phylosophia@ui.ac.id

Abstract — Classification of spinal cord cells is a fundamental step in the diagnosis of haematological diseases, but manual processes have limitations in terms of variability and scalability. This project aims to develop a deep learning system that can classify spinal cord cells into seven morphological classes automatically. This research applied the ReXNet-150 architecture model to a dataset consisting of 3500 cell images. The method used includes several stages, starting from Exploratory Data Analysis (EDA) to ensure data quality, handling blurry images using unsharp masking techniques, to model implementation. To facilitate user interaction, a web-based graphical user interface (GUI) using Gradio and Hugging Face Space was built to enable real-time classification. Results from the confusion matrix show that the model works well, especially in the Eosinophil, Segmented Neutrophil, and Promyelocyte classes. However, the model still has difficulty in distinguishing some cell types with similar morphology, such as the Not Identifiable and Monocyte classes. Overall, the system succeeded in being an accessible solution for cell classification, although improvements are still needed to handle more ambiguous classes.

Keyword — Convolutional Neural Network (CNN), Grad-CAM, RexNet-150.

Abstrak — Klasifikasi sel sumsum tulang belakang merupakan langkah fundamental dalam diagnosis penyakit hematologi, namun proses manual memiliki keterbatasan dalam hal variabilitas dan skalabilitas. Proyek ini bertujuan untuk mengembangkan sistem deep learning yang dapat mengklasifikasikan sel sumsum tulang belakang ke dalam tujuh kelas morfologi secara otomatis. Penelitian ini menerapkan model arsitektur ReXNet-150 pada dataset yang terdiri dari 3500 gambar sel. Metode yang digunakan mencakup beberapa tahapan, mulai dari Exploratory Data Analysis (EDA) untuk memastikan kualitas data, penanganan gambar buram menggunakan teknik unsharp masking, hingga implementasi model. Untuk memfasilitasi interaksi pengguna, dibangun sebuah graphical user interface (GUI) berbasis web menggunakan Gradio dan Hugging Face Space yang memungkinkan klasifikasi secara real-time. Hasil dari confusion matrix menunjukkan bahwa model bekerja dengan baik, terutama pada kelas Eosinophil, Segmented Neutrophil, dan Promyelocyte. Meskipun demikian, model masih mengalami kesulitan dalam membedakan beberapa jenis sel dengan morfologi yang mirip, seperti pada kelas Not Identifiable dan Monocyte. Secara keseluruhan, sistem ini berhasil menjadi solusi untuk klasifikasi sel yang mudah diakses, walaupun masih diperlukan perbaikan untuk menangani kelas-kelas yang lebih ambigu.

Kata kunci — Convolutional Neural Network (CNN), Grad-CAM, RexNet-150.

I. PENDAHULUAN

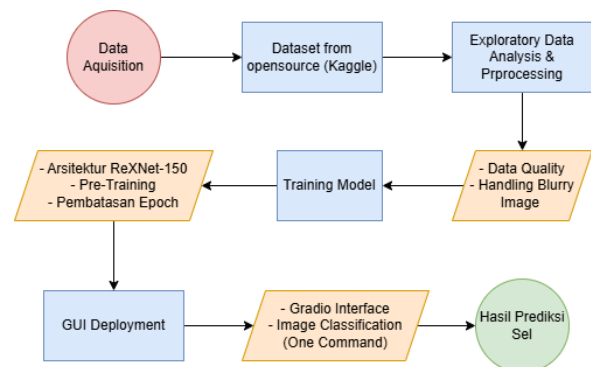
Klasifikasi sel sumsum tulang belakang merupakan langkah fundamental dalam diagnosis dan pemantauan penyakit hematologi seperti leukemia, limfoma, dan berbagai sindrom myelodysplastic. Meskipun teknik molekuler dan imunofenotipe tersedia, analisis sitomorfologi tetap menjadi bagian yang tak terpisahkan karena aksesibilitas, kecepatan, dan signifikansi diagnostiknya, terutama pada evaluasi tahap awal.

Umumnya, apusan sumsum tulang belakang diuji secara manual menggunakan mikroskop oleh seorang ahli patologi, yang kemudian mengevaluasi dan mengklasifikasikan setiap sel berdasarkan bentuk morfologinya. Namun, proses ini sangat bergantung pada keahlian manusia, dan memiliki keterbatasan signifikan dalam hal variabilitas, kelelahan, dan skalabilitas pada throughput klinis yang tinggi.

Belakangan ini, deep learning, khususnya convolutional neural network (CNN), telah menunjukkan keberhasilan luar biasa dalam klasifikasi gambar, termasuk yang banyak dikembangkan dalam pencitraan medis. Sebuah penelitian oleh Matek et al. (2021) mengembangkan dataset berskala besar yang telah dianotasi dan diklasifikasikan oleh ahli, dengan lebih dari 170.000 gambar sel sumsum tulang belakang, menunjukkan bahwa model CNN mengungguli metode klasifikasi berbasis fitur tradisional dengan membedakan morfologi sel yang luas dengan akurasi dan robustness tinggi. Studi tersebut merupakan sumber utama berbagai perkembangan dalam otomatisasi sitologi sumsum tulang belakang, termasuk proyek akhir ini.

Mengacu pada studi-studi yang telah berkembang, proyek ini bertujuan untuk menciptakan sistem deep-learning yang dapat mengklasifikasikan sel sumsum tulang belakang menjadi tujuh kelas morfologi, yaitu Blast, Eosinophil, Lymphocyte, Monocyte, Segmented Neutrophil, Not Identifiable, dan Promyelocyte. Sistem yang digunakan adalah model arsitektur ReXNet-150 untuk melatih algoritma, dan digunakan graphical user interface (GUI) berbasis web menggunakan Gradio dan Hugging Face Space. Pendekatan ini memfasilitasi klasifikasi sel sumsum tulang belakang secara real-time, meskipun untuk skala yang masih terbatas pada tingkat yang mudah yang tidak membutuhkan banyak data.

II. METODE



Gambar 1. Diagram Blok

A. Dataset

Pada proyek ini digunakan *dataset* dari *website* [kegggle.com](https://www.kaggle.com) [1] yaitu data gambar dari sel darah putih yang sudah dipisahkan ke dalam 7 kelompok (6 jenis sel dan satu kelompok sel tidak terdeteksi). Pembagian kelompok tersebut antara lain : (BLA) *Blast*, (EOS) *Eosinophil*, (LYT) *Lymphocyte*, (MON) *Monocyte*, (NGS) *Segmented Neutrophil*, (NIF) *Not Identifiable*, (PMO) *Promyelocyte*. Sumber asli dari *dataset* ini adalah TCIA (*The Cancer Imaging Archive*). Dilakukan pengambilan data di Munich Leukemia Laboratory (MLL), dipindai menggunakan peralatan yang dikembangkan di Fraunhofer IIS, dan diproses lebih lanjut menggunakan perangkat lunak yang dikembangkan di Helmholtz Munich [2]. Diperoleh lebih dari 170.000 sel yang telah dianonimkan dan dianotasi oleh ahli dari apusan sumsum tulang 945 pasien. Sel-sel ini diwarnai menggunakan pewarnaan May-Grünwald-Giemsa/Pappenheim. Diagnosis dalam kelompok pasien ini mencakup berbagai penyakit hematologi.

Tujuh kelompok yang ada pada sumber *kegggle* merupakan penyederhanaan dari sumber asli TCIA. Jumlah awal *datasheet* adalah 7000 data, kemudian dilakukan penyederhanaan kembali sehingga digunakan 700 data untuk serial kelompok, dimana 500 data untuk proses *training* dan 200 data untuk proses validasi GUI. Total *dataset* yang digunakan adalah 4900 data.

Sebelum melakukan serangkaian langkah pemrosesan data, *dataset* berkelompok yang sudah dipisahkan menjadi bagian untuk *training* dan validasi, dimasukkan dalam satu folder *google drive* yang kemudian akan disambungkan pada pengaturan *google colab* untuk *data loading*. Dengan demikian proses pengolahan data dapat dilakukan tanpa perlu mengunduh data dari awal, sehingga menghemat waktu dan penyimpanan.

B. EDA

Tahap awal pemrosesan data adalah dengan melakukan EDA (*Exploratory Data Analysis*). EDA adalah langkah penting dalam analisis data untuk memeriksa distribusi, outlier, dan anomali. EDA juga menyediakan alat untuk pembuatan hipotesis dengan memvisualisasikan dan memahami data, biasanya melalui representasi grafis. EDA bertujuan untuk membantu analisis dalam mengenali pola-pola alami pada data [3]. Untuk pengerjaan proyek kali ini, terdapat beberapa metode yang diterapkan pada EDA, antara lain :

1. Dataset Quality Report and Preview

Tujuan utama bagian ini adalah untuk menilai kualitas *dataset*, mengidentifikasi potensi masalah seperti gambar yang rusak, terlalu gelap, atau memiliki pewarnaan yang tidak sesuai, serta memberikan gambaran umum tentang karakteristik visual data. Dilakukan pemeriksaan apakah file yang diupload adalah file gambar berdasarkan ekstensi (PNG, JPG, JPEG). Kemudian dianalisis tingkat kecerahan gambar. Gambar dikonversi ke skala abu-abu dan dihitung nilai rata-rata piksel. Setelah itu, diperiksa apakah gambar sesuai dengan deskripsi sumber yaitu memiliki pewarnaan ungu May-Grünwald-Giemsa/Pappenheim. Fungsi ini mengkonversi gambar ke ruang warna HSV dan

mendeteksi rentang warna ungu; jika rasio piksel ungu terhadap total piksel di atas ambang batas, pewarnaan ungu dianggap ada. Bagian ini juga mengidentifikasi jenis warna gambar apakah *Grayscale* atau RGB.

2. Blurry Data Handling

Tujuan utama bagian ini adalah untuk menilai kualitas gambar, terutama dari segi ketajaman (*blurriness*), serta memperbaikinya. Ini sangat berguna untuk mengidentifikasi gambar-gambar yang mungkin tidak sesuai untuk pelatihan model *machine learning* karena buram atau memiliki karakteristik yang tidak biasa. Prinsip utama kode yang diterapkan adalah berdasarkan *Laplacian Variance*. Operator Laplacian adalah operator diferensial orde kedua dalam pemrosesan gambar yang bekerja dengan menghitung turunan kedua dari intensitas piksel di seluruh gambar. Operator Laplacian akan menyoroti area di mana terjadi perubahan intensitas piksel, yang secara efektif mengidentifikasi tepi dalam sebuah gambar. Gambar yang tajam memiliki banyak area dimana intensitas piksel berubah dengan cepat, sedangkan gambar buram cenderung lebih kecil dan lebih seragam.

Setelah mendeteksi gambar yang buram, dilakukan proses perbaikan keburaman dengan teknik *unsharp masking*. Prinsip dari teknik ini adalah gambar asli akan 'dikurangi' dengan versi buramnya sendiri. Pada awal, gambar asli akan di-blur menggunakan filter Gaussian (*low-pass*) untuk menghilangkan detail halus dan hanya menyisakan informasi kontras yang kasar atau transisi intensitas yang lambat. Kemudian, gambar yang diburamkan tersebut dikurangkan dari gambar aslinya. Hasilnya adalah sebuah gambar baru yang hanya menampilkan detail dan tepi tajam dari gambar asli yang hilang saat diburamkan. Gambar ini dikenal sebagai "masker detail" atau "edge mask" karena menunjukkan perbedaan antara gambar asli dan versi buramnya. Terakhir, "masker detail" yang telah diekstraksi ditambahkan kembali ke gambar asli. Besaran detail yang ditambahkan dikendalikan oleh parameter "Amount" atau "Gain". Penambahan detail ini memperkuat kontras di sepanjang tepi gambar, memberikan ilusi visual gambar yang lebih tajam.


C. Model ResNet 150

Model ResNet 150 merupakan salah satu bentuk algoritma Convolutional Neural Network (CNN) yang dapat digunakan untuk melakukan *image classification* secara efektif dan akurat dengan tujuan utama yaitu menghasilkan hasil klasifikasi dengan tingkat akurasi yang tinggi sekaligus mengoptimalkan sumber daya komputasi [4].

Model tersebut juga mengadopsi model ResNet atau ImageNet sekaligus memperkenalkan *channel ratio regularization* yang berfungsi dalam menyesuaikan dimensi maupun ukuran dari *channel* pada setiap layer *convolution* yang menjadikan model tersebut memiliki kemampuan

untuk ‘belajar’ atau menerima ‘pengetahuan’ lebih banyak *features* yang berkaitan dari gambar yang tersedia.

Desain *building blocks* model algoritma RexNet sendiri, terinspirasi dari MobileNet2 yang menggunakan *inverted bottleneck design* yang membagi *building blocks* menjadi tiga bagian, yaitu *1x1 expansion convolution*, *3x3 depthwise convolution*, dan *1x1 projection convolution* dimana desain tersebut memungkinkan model RexNet ‘mempelajari’ lebih banyak *features* sekaligus mengurangi kebutuhan parameter yang diperlukan serta meringankan komputasi numerik kompleks – *depthwise convolution layer*.



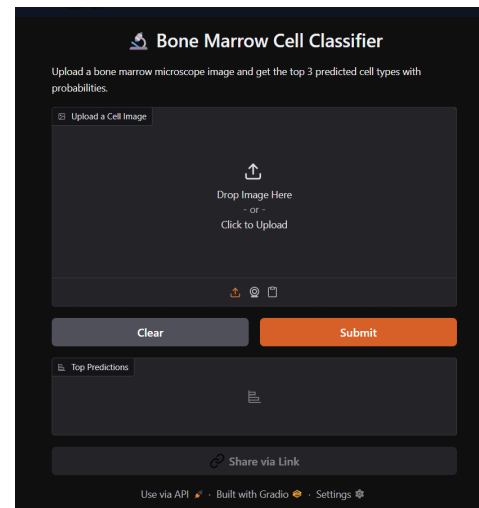
Gambar 2. Hasil *preview* 5 sampel data per kelompok.

Gambar diagram blok di atas merupakan alur bekerja model RexNet secara sederhana, dimana mengekstraksi fitur dari patch gambar berukuran $h \times w \times c$ dengan dua tahap RNN. Pertama, patch direpresentasikan menjadi urutan dan diproses oleh RNN satu arah (R1), lalu hasilnya dikonsolidasikan dan diteruskan ke RNN dua arah (R2). Output RNN kemudian perlu digabung dan diproyeksikan secara linear menjadi vektor ukuran tetap. Vektor tersebut mewakili patch dan dikirim ke classifier berlapis. Terakhir, proses early exit berbasis konsistensi dilakukan untuk menghentikan inferensi lebih awal jika prediksi dianggap cukup meyakinkan [5].

Dalam proyek ini, penulis memanfaatkan model RexNet yang memiliki fungsi *pre-trained* yang memungkinkan algoritma melakukan ‘pembelajaran’ dengan mengambil *weights* maupun melakukan *fine tuning* dari *training model* yang sudah dilakukan sebelumnya, misalnya menggunakan ImageNet, sehingga dapat menghemat jumlah epoch yang perlu dilakukan serta mengurangi waktu training model yang cenderung lama, terlebih dataset yang dibutuhkan memiliki total 3500 gambar.

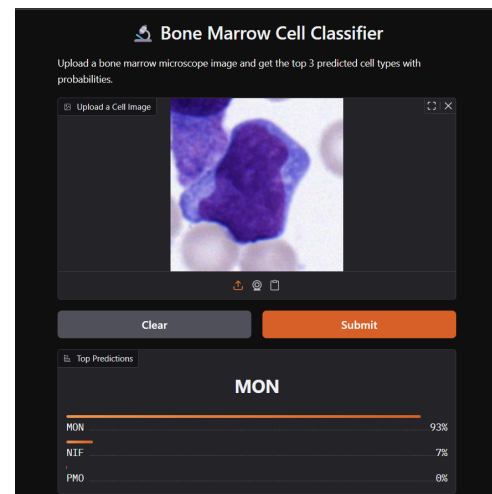
D. GUI

Sebagai pelengkap dan untuk memfasilitasi penggunaan model yang telah terlatih untuk klasifikasi sel sumsum tulang belakang, graphical user interface (GUI) diimplementasikan menggunakan Gradio sebagai kerangka kerja dan platform Hugging Face Space. Metode ini dipilih karena kemampuannya untuk menyediakan antarmuka interaktif dan real-time untuk tugas klasifikasi sel yang dapat diakses melalui situs terbuka, sehingga mengurangi kebutuhan akan aplikasi yang kompleks. Tujuan dari GUI ini adalah untuk memungkinkan pengguna mengunggah citra mikroskop sel sumsum tulang belakang dan memperoleh hasil prediksi jenis sel beserta nilai confidence terkait. Proses ini dapat dilakukan dengan mudah oleh siapa pun melalui one step command.



Gambar 3. Tampilan Utama GUI

Antarmuka yang dibuat menggunakan Gradio, sebuah *library* Python yang terbuka yang dapat menerapkan model *machine learning* dengan menggunakan GUI yang mudah dan sederhana. GUI yang digunakan terhubung dengan fungsi antarmuka yang ditandai dengan kode `gr.Interface()`, yang kemudian akan menghubungkan input dan output dengan *widget front-end*. Pada saat ingin mengunggah sebuah gambar, format yang diterima adalah format gambar umum, dan keluaran yang diberikan oleh sistem adalah sebuah tulisan yang menampilkan tiga prediksi utama yang diperkirakan oleh sistem, dengan menampilkan nama bagi yang memiliki tingkat *confident* paling tinggi.



Gambar 4. Tampilan GUI Setelah Menunjukkan Hasil


GUI ini diluncurkan menggunakan kode perintah `demo.launch(share=True)`. Untuk dapat menampilkan dengan lengkap, beberapa hal esensial telah diunggah ke repositori Hugging Face, yaitu: `app.py` (skrip Gradio), `bone_marrow_model.pth` (model yang telah dilatih), dan `requirements.txt` (daftar dependensi Python). Setelah di `commit`, platform Hugging Face secara otomatis akan membangun lingkungan dan menjalankan skrip aplikasi, sehingga antarmuka pengguna grafis (GUI) dapat diakses oleh publik. Arsitektur sistem ini memungkinkan jalur

end-to-end dari pelatihan di Colab hingga interaksi pengguna melalui web, membentuk platform inferensi model yang dapat direproduksi dan berskala untuk klasifikasi sel sumsum tulang.

III. HASIL DAN DISKUSI


A. EDA

Sistem EDA yang diterapkan untuk proses pengolahan data proyek ini menunjukkan output jumlah data yang dianalisis sesuai dengan jumlah data yang diimpor yaitu 3500 data. Tidak ditemukan file *corrupt*, file yang terlalu gelap dan tidak ada data tanpa pewarnaan ungu sesuai penjelasan sumber data. Tipe warna gambar data ini adalah RGB. Dalam tahap ini, diberikan *preview* 5 gambar untuk masing-masing kelompok dataset.



Gambar 5. Hasil *preview* 5 sampel data per-kelompok.

Proses *handling blurry images* yang diterapkan mendeteksi 30% data dengan tingkat buram/*blur* paling tinggi untuk ditangani *Unsharp Masking*. Hasil dari *pre-processing* data ini, dapat dilihat melalui gambar dibawah. Terlihat perbedaan kualitas gambar sebelum dan sesudah diperbaiki. Hal ini akan meningkatkan kualitas sistem pengolahan data dan *output*.




Gambar 6. Hasil dari *Handling Blurry Images*

B. Learning Curves

Hasil dari model klasifikasi sel sumsum tulang belakang telah dievaluasi dengan menampilkan kurva pembelajaran, atau *learning curves*, yang terjadi selama pelatihan. Hal ini termasuk *training loss* dan *validation*, akurasi, dan skor F1 selama periode waktu yang berurutan. Model yang


digunakan didasarkan pada arsitektur ReXNet-150 dan dilatih menggunakan pembagian bertingkat. Evaluasi ini dilakukan untuk menilai seberapa baik model tersebut dapat digeneralisasi ke data validasi yang tidak terlihat.

Kurva kerugian menunjukkan penurunan tajam dalam kerugian pelatihan (*train loss*) selama periode awal, yang menunjukkan bahwa model dengan cepat mempelajari fitur-fitur yang relevan dari data pelatihan. Namun, *validation loss* tidak mengikuti pola yang sama. Sebaliknya, *validation loss* cenderung terus mendarat selama 6 epoch, ini menunjukkan bahwa tidak terjadi *loss* terhadap validasi yang dilakukan oleh model. Perbedaan antara kedua ini menunjukkan indikator dari *overfitting*, dimana model menjadi semakin sesuai dengan pelatihan yang dilalui.




Gambar 7. Grafik *Loss Value Train vs Validation*

Selanjutnya, kurva akurasi menunjukkan peningkatan yang konsisten dalam akurasi pelatihan, mencapai nilai yang mendekati 0,95 pada akhir epoch. Akurasi validasi juga meningkat selama fase pelatihan awal, hingga mencapai puncaknya pada sekitar 0,79 pada epoch ketiga, dan kemudian stabil. Hal ini menunjukkan bahwa model ini mampu mencapai kinerja klasifikasi yang relatif tinggi pada data yang tidak terlihat, meskipun ada kesenjangan yang nyata antara akurasi pelatihan dan validasi, yang memperkuat adanya *overfitting*.



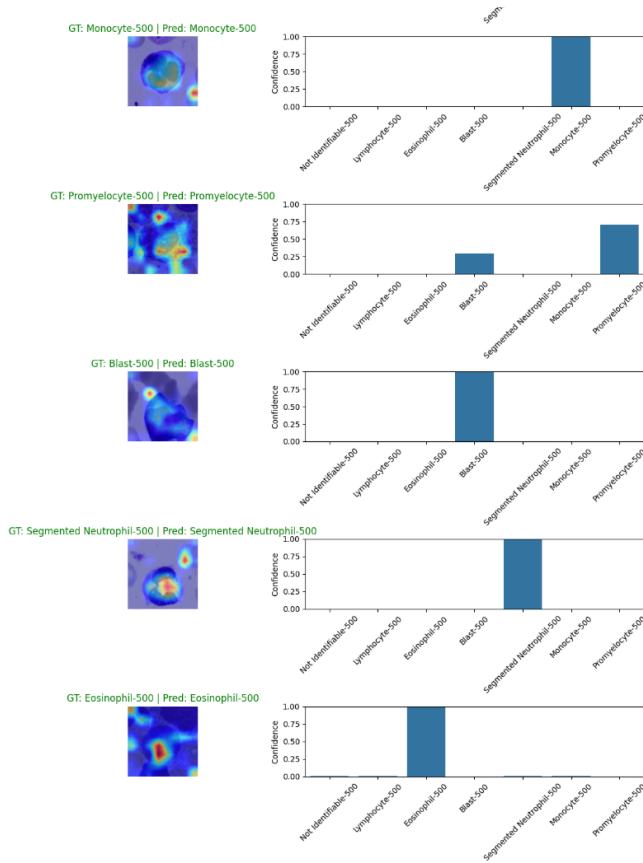
Gambar 8. Grafik *Accuracy Train vs Validation*

Kurva skor F1, yang memperhitungkan presisi dan recall, menunjukkan tren yang sama. Skor F1 pelatihan terus meningkat dan mendekati 0,96, yang mencerminkan akurasi pelatihan. Akan tetapi, skor F1 validasi mencapai puncaknya sekitar 0,79 pada epoch ketiga dan kemudian sedikit menurun sebelum menjadi stabil. Skor ini menunjukkan bahwa model ini cukup baik.



Gambar 9. Grafik F1-Score Train vs Validation

B. Grad-CAM dan Bar Plot




Gambar 10. Visualisasi Klasifikasi melalui Grad-CAM dan Bar Plot

Gambar di atas merupakan hasil klasifikasi yang dihasilkan model algoritma RexNet-150 yang digunakan, dimana terdapat dua jenis grafik yang berhasil ditampilkan, yaitu *Gradient-weighted Class Activation Mapping* (Grad-CAM) dan *bar plot*. Grad-CAM merupakan suatu teknik visualisasi yang menampilkan skala berupa *heatmap* yang dapat menyoroti area krusial yang dianggap berkaitan terhadap input gambar yang memanfaatkan gradien dari kelas target yang mengalir ke *convolution layer* terakhir. Pada gambar terlihat bahwa setiap input gambar memiliki karakteristik *heatmap* masing-masing, dimana warna merah pada satu titik yang berada pada tepat di inti ataupun bagian khas sel yang menunjukkan area yang paling berkontribusi terhadap keputusan model, sedangkan warna kuning hingga biru menunjukkan area yang tidak terlalu berkaitan dengan keputusan model atau tidak relevan.

Sementara, *bar plot* digunakan untuk menunjukkan nilai keterkaitan antar masing-masing kelas terhadap input gambar melalui *confidence level* yang ditunjukkan oleh sumbu-y dan label setiap kelas sel ditunjukkan oleh sumbu-x. Semakin tinggi bar yang dihasilkan maka menunjukkan bahwa pada suatu kelas memiliki *confidence level* yang besar, adanya keyakinan model dalam mengelompokkan kelas dengan tepat dimana idealnya setiap klasifikasi menghasilkan *confidence level* yang sempurna – 100% –. Tidak menutup kemungkinan bahwa model akan memiliki nilai *confidence level* pada beberapa kelas yang menunjukkan bahwa input gambar tertentu memiliki karakteristik morfologis pada inti sel yang mungkin serupa, tetapi hal tersebut dapat memberikan ambiguitas atau bias antar kelas terlebih ketika *confidence level* yang dihasilkan memiliki nilai yang relatif mirip. Pada gambar di atas, hasil klasifikasi cenderung menunjukkan keputusan yang baik dimana tidak ada input gambar yang mengalami kesalahan klasifikasi atau *mismatch* dengan nilai *confidence level* yang tinggi pada satu kelas.

C. Confusion Matrix



Gambar 11. Visualisasi Klasifikasi melalui Grad-CAM dan Bar Plot

Hasil *confusion matrix* tersebut menunjukkan bahwa model klasifikasi bekerja dengan cukup baik secara keseluruhan, terutama pada kelas Eosinophil (46/50 benar), Segmented Neutrophil (49/50 benar), dan Promyelocyte (45/50 benar) yang memiliki akurasi sangat tinggi. Namun, model masih mengalami kesalahan yang cukup signifikan pada kelas Not Identifiable dan Monocyte, dengan masing-masing hanya 27 dan 33 prediksi yang benar dari 50 sampel. Kelas Not Identifiable banyak diklasifikasikan salah sebagai Blast, Lymphocyte, dan Monocyte, sementara Monocyte sering tertukar dengan Blast dan Promyelocyte. Hal tersebut menunjukkan bahwa beberapa jenis sel masih sulit dibedakan oleh model, kemungkinan karena kemiripan morfologis atau kualitas gambar. Secara umum, model menunjukkan performa yang baik dengan kebutuhan perbaikan pada kelas yang lebih ambigu.

IV. KESIMPULAN

Berdasarkan penelitian yang dilakukan, model algoritma ReXNet-150 terbukti efektif dan akurat untuk klasifikasi sel sumsum tulang belakang ke dalam tujuh kelas yang ditentukan. Keakuratan model ini divalidasi melalui analisis confusion matrix yang menunjukkan capaian akurasi keseluruhan sebesar 80,29%. Model menunjukkan performa sangat tinggi pada kelas spesifik seperti Segmented Neutrophil (49/50 benar) dan Eosinophil (46/50 benar), meskipun masih terdapat tantangan pada kelas yang ambigu secara morfologis. Kedepannya, penelitian ini dapat dikembangkan untuk aplikasi klasifikasi sel secara multi-label serta menggunakan jumlah kelas yang lebih banyak sebagai dataset

UCAPAN TERIMA KASIH

Dengan tulus, penulis ingin mengucapkan terima kasih yang sebesar-besarnya kepada Bapak Moch Ikhsan atas semua bantuan, bimbingan, dan pembelajaran berharga yang telah diberikan dalam mata kuliah Pengolahan Sinyal Medis. Berkat arahan dari Bapak/Ibu, pengerjaan proyek ini dapat berjalan dengan cukup lancar dan memberikan banyak wawasan baru bagi penulis.

Ucapan terima kasih juga penulis sampaikan kepada semua teman-teman yang telah setia membantu, memberikan masukan, dan menyemangati saya, khususnya di saat penulis menghadapi kendala dalam proses pengerjaan. Tanpa dukungan teman sekalian, proyek ini mungkin tidak akan selesai dengan baik.

DAFTAR ACUAN

- [1] D. Roy, "bone-marrow-cell-classification," Kaggle.com, 2021, doi: <https://doi.org/10.7937/TCIA.AXH3-T579>.
- [2] The, "An Expert-Annotated Dataset of Bone Marrow Cytology in Hematologic Malignancies," The Cancer Imaging Archive (TCIA), Sep. 26, 2024. https://www.cancerimagingarchive.net/collection/bone-marrow-cytomorphology_mil_helmholtz_fraunhofer/
- [3] M. Komorowski, D. C. Marshall, J. D. Saliccioli, and Y. Crutain, "Exploratory Data Analysis," PubMed, 2016. <https://www.ncbi.nlm.nih.gov/books/NBK543641/>
- [4] Y. Liu, "Efficient Image Classification Using ReXNet: Distinguishing AI- Generated Images from Real Ones," Proceedings of the 1st International Conference on Engineering Management, Information Technology and Intelligence, pp. 234–238, 2024, doi: <https://doi.org/10.5220/0012925200004508>.
- [5] X. Qian, R. Hang, and Q. Liu, "ReX: An Efficient Approach to Reducing Memory Cost in Image Classification," Proceedings of the ... AAAI Conference on Artificial Intelligence, vol. 36, no. 2, pp. 2099–2107, Jun. 2022, doi: <https://doi.org/10.1609/aaai.v36i2.20106>.